

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ
ДОНЕЦКОЙ НАРОДНОЙ РЕСПУБЛИКИ
ГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
«ДОНЕЦКИЙ НАЦИОНАЛЬНЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

МЕТОДИЧЕСКИЕ РЕКОМЕНДАЦИИ
для выполнения контрольных работ по дисциплине
«Интеллектуальный анализ данных»

Донецк
2021

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ
ДОНЕЦКОЙ НАРОДНОЙ РЕСПУБЛИКИ
ГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
«ДОНЕЦКИЙ НАЦИОНАЛЬНЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

КАФЕДРА АВТОМАТИЗИРОВАННЫХ СИСТЕМ УПРАВЛЕНИЯ

МЕТОДИЧЕСКИЕ РЕКОМЕНДАЦИИ
для выполнения контрольных работ по дисциплине
«Интеллектуальный анализ данных»

для обучающихся по направлениям подготовки
09.03.01 «Информатика и вычислительная техника»,
09.03.02 «Информационные системы и технологии»,
02.03.02. «Фундаментальная информатика и информационные технологии»
заочной формы обучения

РАССМОТРЕНО
на заседании кафедры
«Автоматизированные системы
управления»
Протокол № 4 от 16.11.2021 г.

УТВЕРЖДЕНО
на заседании учебно-издательского
совета ДОННТУ
Протокол № 14 от 16.12.2021 г.

Донецк
2021

УДК 004.8(076)

ББК 32.813я73

М 54

Составитель:

Васяева Татьяна Александровна – кандидат технических наук, доцент, доцент кафедры автоматизированных системы управления.

М 54

Методические рекомендации для выполнения контрольных работ по дисциплине «Интеллектуальный анализ данных» [Электронный ресурс]: для обучающихся по направлениям подготовки 09.03.01 «Информатика и вычислительная техника», 09.03.02 «Информационные системы и технологии», 02.03.02. «Фундаментальная информатика и информационные технологии» заочной формы обучения/ ГОУВПО «ДОННТУ», каф. автоматизированных системы управления; сост. Т. А. Васяева. – Донецк: ДОННТУ, 2021. – Систем. требования: Acrobat Reader. – Загл. с титул. экрана.

Методические рекомендации разработаны с целью оказания помощи обучающимся в усвоении теоретического материала и получении практических навыков по дисциплине «Интеллектуальный анализ данных», которые содержат задания для выполнения контрольных работ по курсу.

УДК 004.8(076)

ББК 32.813я73

СОДЕРЖАНИЕ

Введение	5
Контрольная работа № 1. Нейронные сети для прогнозирования временных рядов.....	6
Список использованных источников	19

ВВЕДЕНИЕ

Дисциплина рассматривает вопросы получения данных из различных источников, контроля целостности и качества полученных данных, интеллектуального анализа данных, машинного обучения и глубокого обучения.

Цели дисциплины: ознакомление с теоретическими аспектами технологии Data Mining, Machine Learning and Deep Learning; ознакомление студентов с различными типами данных, методами их получения и оценкой качества; ознакомление с классическими задачами интеллектуального анализа данных; рассмотрение моделей для решения базовых задач интеллектуального анализа данных и изучение методов для их разработки; приобретение практических навыков по использованию инструментальных средств Data Mining, Machine Learning and Deep Learning.

В результате освоения дисциплины студент должен знать: место и значение анализа данных, основные этапы интеллектуального анализа данных; основные понятия, задачи, практическое применение, модели и методы интеллектуального анализа данных; принципы сбора данных из различных источников и их обработки; основы машинного и глубокого обучения; уметь: применять полученные знания при разработке, внедрении и эксплуатации автоматизированных и информационно-аналитических систем; получать данные из различных источников, выполнять их анализ и предварительную обработку; подбирать необходимые методы интеллектуального анализа в соответствии с задачами аналитической работы; выполнять программную реализацию методов интеллектуального анализа данных для решения типовых практических задач.

В методических указаниях приведена тема, необходимый теоретический и иллюстративный материал для выполнения контрольной работы.

Контрольная работа №1.

Тема: нейронные сети для прогнозирования временных рядов.

Цель работы: изучение возможности нейронных сетей применительно к прогнозированию временных рядов; разработка архитектуры и обучение нейронной сети для прогнозирования временного ряда.

1.1. Понятие временного ряда

Временной ряд представляет собой последовательность наблюдений за изменениями во времени значений параметров некоторого объекта или процесса. Строго говоря, каждый процесс непрерывен во времени, то есть некоторые значения параметров этого процесса существуют в любой момент времени. Но для задач анализа не нужно знать значения параметров объектов в любой момент времени. Интерес представляют временные отсчеты – значения зафиксированные в некоторые, обычно равноотстоящие моменты времени. Отсчеты могут браться через различные промежутки: через минуту, час, день, неделю, месяц или год – в зависимости от того, насколько детально должен быть проанализирован процесс. В задачах анализа временных рядов мы имеем дело с дискретным временем, когда каждое наблюдение за параметром образует временной отсчет. Все временные отсчеты нумеруются в порядке возрастания. Тогда временной ряд будет представлен в следующем виде: $X = \{x_1, x_2, \dots, x_n\}$.

Временные ряды могут быть одномерными и многомерными. Одномерные ряды содержат наблюдения за изменением только одного параметра исследуемого процесса или объекта, а многомерные – за двумя параметрами или более. Трехмерный временной ряд, содержащий наблюдения за тремя параметрами – X , Y и Z – процесса F , можно записать в следующем виде: $F = \{(x_1, y_1, z_1); (x_2, y_2, z_2); \dots; (x_n, y_n, z_n)\}$.

Значения временного ряда получаются путем регистрации соответствующего параметра исследуемого процесса через определенные промежутки времени. При этом в зависимости от природы данных и характера

решаемых задач регистрируется либо текущее значение (например, температура или курс валюты), либо сумма значений, накопленная за определенный интервал времени (например, сумма продаж за день, количество клиентов за неделю и т.д.). В последнем случае может использоваться не только суммирование, но и среднее значение за интервал, минимальное, максимальное значение или медиана. Так, исследователя может интересовать средний объем продаж за неделю, максимальный курс доллара к рублю, минимальная температура за месяц и т.д.

Цель анализа временного ряда – построение его математической модели, с помощью которой можно обнаружить закономерности поведения ряда, а также построить прогноз его дальнейшего развития.

Задача одношагового прогнозирования может быть сформулирована так: имеется временной ряд $X = \{x_1, x_2, \dots, x_n\}$, представленный своими значениями, лагами (ЛАГ □ от англ. lag — запаздывание, временной лаг — показатель, отражающий отставание или опережение во времени одного явления по сравнению с другими) в предшествующие моменты времени X_{t-k}, X_{t-k+1}, X_t , где t — текущий момент времени, k — глубина исторической выборки. Необходимо найти величину изменения ее значения, которое произойдет в следующий момент времени, на основе анализа прошлых значений.

1.2. Глубокие нейронные сети

Глубокие нейронные сети в настоящее время становятся одним из самых популярных методов машинного обучения. Они показывают лучшие результаты по сравнению с альтернативными методами в таких областях, как распознавание речи, обработка естественного языка, компьютерное зрение, медицинская информатика и др. Одна из причин успешного применения глубоких нейронных сетей заключается в том, что сеть автоматически выделяет из данных важные признаки, необходимые для решения задачи. В альтернативных алгоритмах машинного обучения признаки должны выделяться людьми, существует специализированное направление исследований — инженерия признаков

(feature engineering). Однако при обработке больших объемов данных нейронная сеть справляется с выделением признаков гораздо лучше, чем человек.

Нейронные сети прямого распространения получают на вход некоторый вектор данных и пытаются по нему предсказать тот или иной результат. Вектор этот должен для данной архитектуры сети иметь одну и ту же размерность. В результате получается, что сеть может постоянно делать одну и ту же операцию: предсказывать выход по входам, причем рассматривать каждый следующий вход совершенно независимо от предыдущего.

Чтобы прогнозировать временной ряд такими нейронными сетями можно зафиксировать некоторую длину истории l и подавать на вход нейронной сети предыдущие l значений ряда: будем пытаться предсказать значение x_n из ряда $x_1; x_2; \dots; x_{n-2}; x_{n-1}$ как функцию $x_n = f(x_{n-1}; \dots; x_{n-l})$. Например, если $l = 5$, то обучающий массив имеет вид табл. 1.1.

Таблица 1.1. Обучающий массив

№	x_{n-5}	x_{n-4}	x_{n-3}	x_{n-2}	x_{n-1}	x_n	x_{n+1}
1	x_1	x_2	x_3	x_4	x_5	x_6	x_7
2	x_2	x_3	x_4	x_5	x_6	x_7	x_8
3	x_3	x_4	x_5	x_6	x_7	x_8	x_9
4	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
5	x_5	x_6	x_7	x_8	x_9	x_{10}	x_{11}
...

Если $l = 3$, то пример такой архитектуры показан на рис. 1.1. Здесь выходы получаются из трех предыдущих входов: $y_4 = f(x_1; x_2; x_3)$, $y_5 = f(x_2; x_3; x_4)$ и $y_6 = f(x_3; x_4; x_5)$.

Заметим, что веса у всех изображенных сетей общие, то есть такая сеть будет рассматривать последовательность из тренировочных данных как много независимых тестовых примеров.




Рисунок 1.1. Архитектура обычной нейронной сети с фиксированным размером истории. Одна и та же нейронная сеть применяется к последовательным окнам входа.

Для некоторых задач такая идея может сработать, но часто длина зависимости тоже не известна заранее, а предсказание получить, тем не менее, нужно в любой момент времени. С последовательностями переменной длины могут работать рекуррентные НС. К тому же иногда нужно чтобы нейронная сеть могла запоминать что-то из истории приходящих на вход данных, сохранять некое внутреннее состояние, которое можно было бы потом использовать для предсказания будущих элементов последовательности.

1.3. Рекуррентные нейронные сети

В рекуррентных же сетях связи между нейронами могут идти не только от нижнего слоя к верхнему, но и от нейрона к «самому себе», точнее, к предыдущему значению самого этого нейрона или других нейронов того же слоя. Именно это позволяет отразить зависимость переменной от своих значений в разные моменты времени: нейрон обучается использовать не только текущий вход и то, что с ним сделали нейроны предыдущих уровней, но и то, что происходило с ним самим и, возможно, другими нейронами на предыдущих входах.

Рекуррентная сеть - это сеть с обратной связью (рис. 1.2). То есть выход сети на шаге $t-1$ является входом на шаге t . Такую архитектуру можно развернуть во времени и получится аналог сети прямого распространения. В отличие от сетей прямого распространения в рекуррентных сетях все последующие шаги зависят как от входа на текущем шаге, так и от выходов на предыдущих шагах. Обратные связи придают рекуррентным нейронным сетям дополнительные возможности. Хотя в принципе рекуррентные сети продолжают классические идеи достаточно прямолинейно, нам теперь становится сложно просто взять и применить алгоритм обратного распространения ошибки для их обучения.

В прямой нейронной сети ошибка на конкретном нейроне вычисляется как функция от ошибок нейронов, которые используют его выходное значение. Но что делать в случае, когда нейрон принимает в качестве входа результат вычисления в нем самом? На самом деле, конечно, эта петля в графе вычислений нам только кажется. Мы действительно используем результаты вычисления той же функции, но это результаты вычисления функции на предыдущих шагах. В результате вычисление, которое делает рекуррентная сеть, можно развернуть обратно до начала последовательности (рис. 1.2).

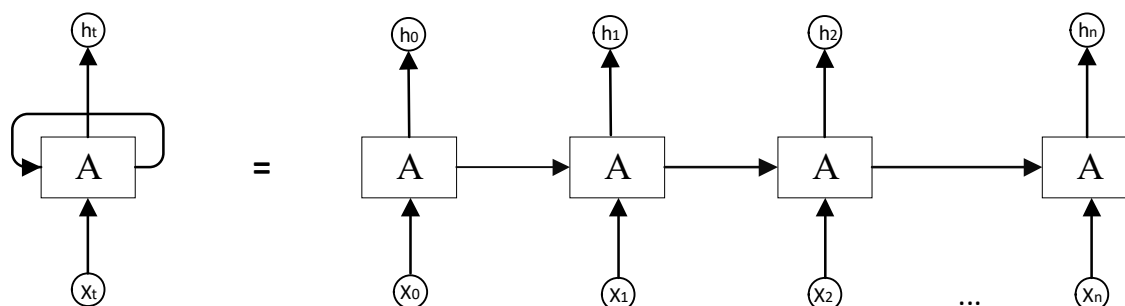


Рисунок 1.2. Фрагмент рекуррентной нейронной сети и рекуррентная нейронная сеть в развертке.

Можно сказать, что на каждом шаге сеть создает несколько копий самой себя. Каждая из этих копий принимает на вход текущее окно в определенный момент времени (определенную часть последовательности) и значение, полученное из предыдущей копии, затем каким-то образом их комбинирует и передает получившийся результат в следующий элемент (рис. 1.3).

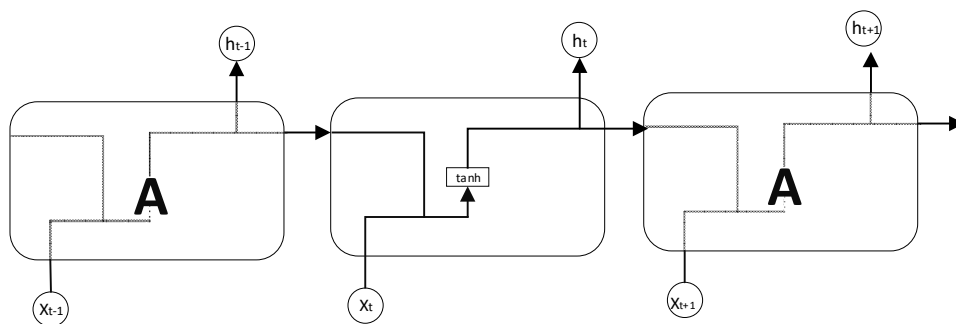


Рисунок 1.3. Повторяющийся модуль в стандартном RNN содержит один слой.

Simple RNN

Архитектура простой рекуррентной нейронной сети (Simple RNN) показана на рис. 1.3. Входы и скрытые состояния будем считать векторами. Таким образом, на каждом шаге мы фактически обучаем глубокую нейронную сеть, в которой столько слоев, сколько элементов в последовательности мы уже видели. Основное ее отличие от обычной нейронной сети, которые мы рассматривали до сих пор, состоит в том, что веса на каждом слое одинаковые, все слои делят одни и те же переменные между собой (shared weights).

GRU (UpdateGateandResetGate)

В GRU (рис. 1.4-1.5) используются фильтры обновления и сброса, которые определяют, какую информацию следует передавать на выход. Особенность такой архитектуры заключается в том, что можно научить сеть хранить только ту информацию, причем достаточно долго, которая имеет отношения к прогнозу.

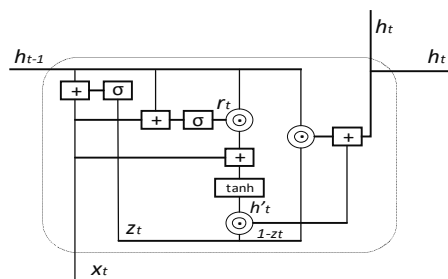


Рисунок 1.4. Один нейрон GRU сети.

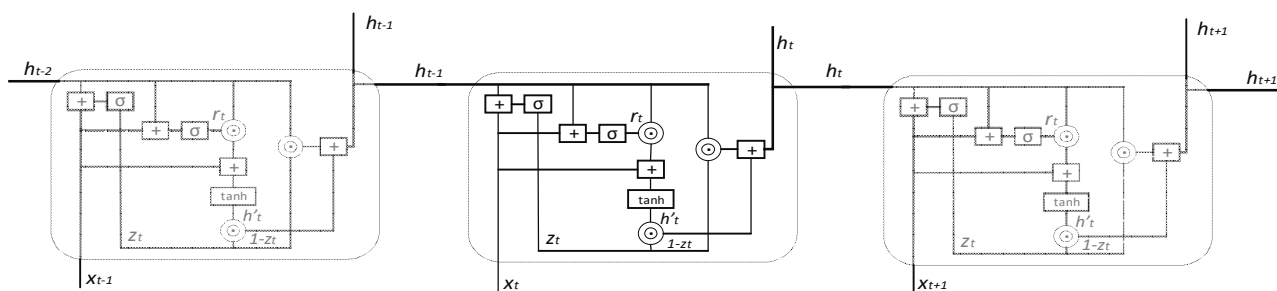


Рисунок 1.5. – Повторяющийся модуль в GRU

Введем обозначения:



Рисунок 1.6. – Операторы в GRU

Long short-term memory (LSTM)

Структура LSTM тоже напоминает такую же, как на рисунке 5 цепочку, но модули выглядят и взаимодействуют иначе (рис. 1.3).

Ключевой компонент LSTM – это состояние ячейки. Состояние ячейки участвует в нескольких линейных преобразованиях. LSTM может удалять информацию из состояния ячейки; этот процесс регулируется фильтрами.

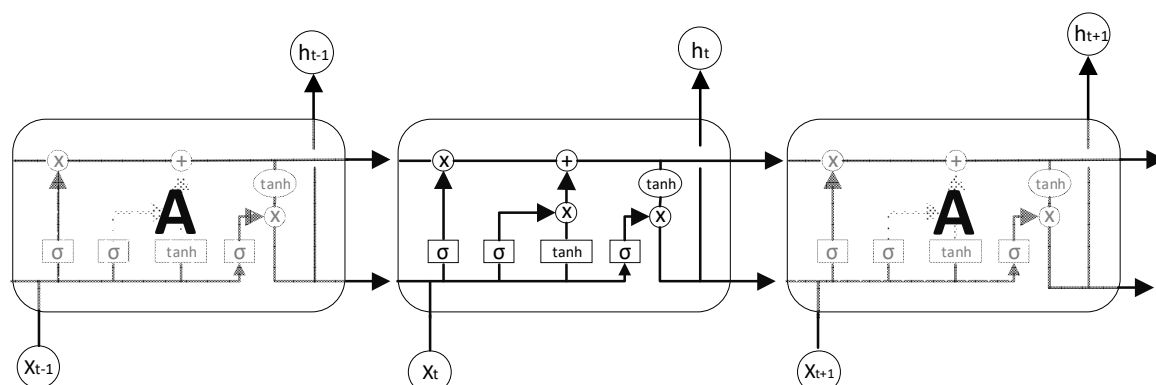


Рисунок 1.7. Рекуррентная LSTM сеть.

Введем обозначения:




Рисунок 1.8 – Операторы в LSTM

1.4. Анализ фондового рынка

Котировка — цена (курс, процентная ставка) товара, которую объявляет продавец или покупатель и по которой они готовы совершить покупку или продажу (предлагается оферта). Обычно подразумевается относительно быстро меняющаяся цена, например биржевая.

На биржах цены регистрирует специальная котировальная комиссия (комитет). Обычно публикуются цены открытия и закрытия биржевой сессии, максимальная и минимальная цена дня. Такие публикации называют «официальная котировка».

Котировки отражают складывающуюся на торгах конъюнктуру рынка, соотношение спроса и предложения.

ОНЛС – это сокращенное обозначение котировок, которые указываются для элементарной диаграммы какого-либо ценового графика. К примеру, им может быть бар или японская свеча. А этой аббревиатуре О обозначает Open – цену открытия интервала, Н означает High — максимум цены интервала, L означает Low – минимум цены интервала и С означает Close – цену закрытия интервала. Каждый график типа ОНЛС представляет собой классический столбиковый график, бар. В нем каждый интервал времени (например, 5 минут) представлен ОНЛС ценами прямо внутри этого интервала. Грубо говоря, это основная единица фьючерсной торговли на FOREX, которая содержит цены открытия и закрытия, максимальное и минимальное значение цены за период времени, содержащийся в баре.

Цена открытия — Open, говорит трейдеру о том, что находилась эта цена в момент самого начала данного бара, то есть в самый начальный момент времени определенного временного отрезка, описанного в баре. Благодаря этому

параметру трейдеру всегда известно с какой цены начался определенный временной отрезок на рынке FOREX. Цена закрытия — Close, является значением, которое приобретает цена за определенный промежуток времени, содержащийся в конкретном баре. Нужно сказать, что цена закрытия может не совпадать с ценой открытия следующего бара, особенно тогда, когда цены меняются очень быстро. Между ценой закрытия старого бара и открытия нового проходит достаточно много времени, которого хватает для изменения цены. Максимальное и минимальное значение цены — High и Low, говорят о наибольшем или наименьшем значении, которое приобреталось ценой за время формирования одного конкретного бара. Каждый опытный трейдер по информации, которая содержится в баре, сможет сделать анализ и предоставить качественный вывод о том, что делается на рынке в данный момент, каково его поведение, какие тенденции можно наблюдать.

Для примера можно привести следующее: если цены открытия и закрытия находятся рядом друг с другом, располагаясь примерно в середине бара, то ни продавцы, ни покупатели не превосходили друг друга в течении указанного периода времени. Рынок был относительно и в целом спокоен.

Если цены открытия и закрытия расположены рядом друг с другом, но также расположены сверху и снизу бара, то это говорит о том, что рынок, скорее всего, вскоре изменит свое движение в определенную сторону. Таким образом, должно быть понятно, что внимательное изучение бара позволит трейдеру получить важную информацию касательно того, кто именно доминировал на FOREX за указанный промежуток времени — продавцы или покупатели. Что это дает — если доминируют продавцы, то точка закрытия будет ниже точки открытия. Если доминируют покупатели — то будет наоборот. Трейдер сможет, благодаря этой информации, лучше понять рынок и сформировать свой собственный прогноз на его будущее состояние в течение определенного времени.

Оптимально использовать одну неделю, но можно и один день. Кроме того, продолжительность периода времени, которое используется для сбора цен в бар,

можно варьировать согласно своей собственной стратегии. Так, вариаций существует очень много, буквально от одной минуты до одного месяца.



Рисунок 1.9. Классический столбиковый график, бар




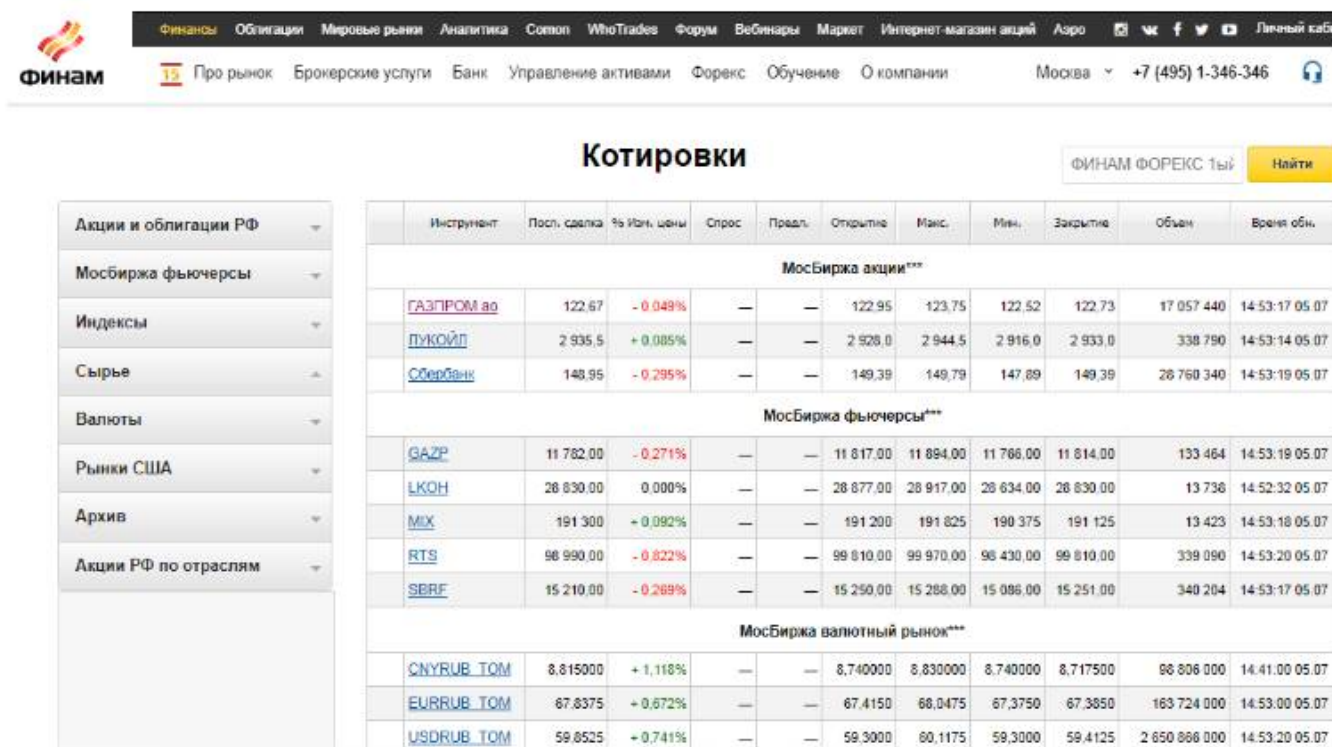
Рисунок 1.10. Японские свечи

Трейдер должен выбрать именно такой период, который наиболее хорошо удовлетворяет его целям. Использовать можно заданные интервалы, либо прописать нужное время самостоятельно. Иногда есть смысл собирать в бар дополнительную информацию, которая сможет накапливаться в течении определенного периода времени. Например, это может быть общий объем

ордеров на рынке за минуту. Собираться может статистика по ордерам, как на продажу, так и на покупку. Кроме того, можно собирать статистику по количеству тик, по их объему в течении заданного периода. Для некоторых трейдеров эта информация может быть очень важной и полезной.

1.5. Порядок выполнения работы

1. Изучить предметную область. Выбрать данные для анализа <https://www.finam.ru/quotes> (рис. 1.11).



Инструмент	Посл. сделка	% Изм. цены	Спрос	Предл.	Открытие	Макс.	Мин.	Закрытие	Объем	Время обн.
МосБиржа акции***										
ГАЗПРОМ.ао	122.67	- 0.049%	—	—	122.95	123.75	122.52	122.73	17 057 440	14:53:17 05.07
ЛУКОЙЛ	2 935.5	+ 0.085%	—	—	2 928.0	2 944.5	2 916.0	2 933.0	338 790	14:53:14 05.07
Сбербанк	148.95	- 0.295%	—	—	149.39	149.79	147.89	149.39	28 760 340	14:53:19 05.07
МосБиржа фьючерсы***										
GAZP	11 782.00	- 0.271%	—	—	11 817.00	11 894.00	11 766.00	11 814.00	133 464	14:53:19 05.07
LKOH	28 830.00	0.000%	—	—	28 877.00	28 917.00	28 834.00	28 830.00	13 738	14:52:32 05.07
MIX	191 300	+ 0.092%	—	—	191 200	191 825	190 375	191 125	13 423	14:53:18 05.07
RTS	98 990.00	- 0.822%	—	—	99 810.00	99 970.00	98 430.00	99 810.00	339 090	14:53:20 05.07
SBERF	15 210.00	- 0.269%	—	—	15 250.00	15 288.00	15 086.00	15 251.00	340 204	14:53:17 05.07
МосБиржа валютный рынок***										
CNYRUB_TOM	8.815000	+ 1.118%	—	—	8.740000	8.830000	8.740000	8.717500	98 806 000	14:41:00 05.07
EURRUB_TOM	67.8375	+ 0.672%	—	—	67.4150	68.0475	67.3750	67.3850	163 724 000	14:53:00 05.07
USDRUB_TOM	59.8525	+ 0.741%	—	—	59.3000	60.1175	59.3000	59.4125	2 650 866 000	14:53:20 05.07

Рисунок 1.11. Выбор котировки

Компания «ФИНАМ» и их интернет-ресурс [finam.ru](https://www.finam.ru), предоставляют возможность — скачивать котировки в том числе и в больших объемах. После нажатия «Экспорт котировки» представится возможность выгрузки данных в файл (рис. 1.12).

2. Разработать рекуррентную нейросеть для прогнозирования котировок (цена открытия и / или закрытия), для четных вариантов - обязателен минимум

один слой GRU, для не четных - обязателен слой LSTM. Номер варианта совпадает с номером в журнале.

Предусмотреть:

- нормирование / денормирование данных;
- обязательное сохранение / считывание обученной НС;
- отдельный этап тестирования для указанного интервала в будущем;
- вывод и расчет ошибки на обучающих, тестовых (валидационных) данных;
- вывод результатов в файл (дата, спрогнозированное значение, реальное значение (если такое имеется для текущего прогноза), ошибка);
- вывод результатов на графиках (отдельно обучающая выборка, отдельно тестовая и обе на одном графике).

3. Провести эксперименты для разного значения глубины (например, от 200 до 4000 баров) показать результаты экспериментов, сделать выводы.

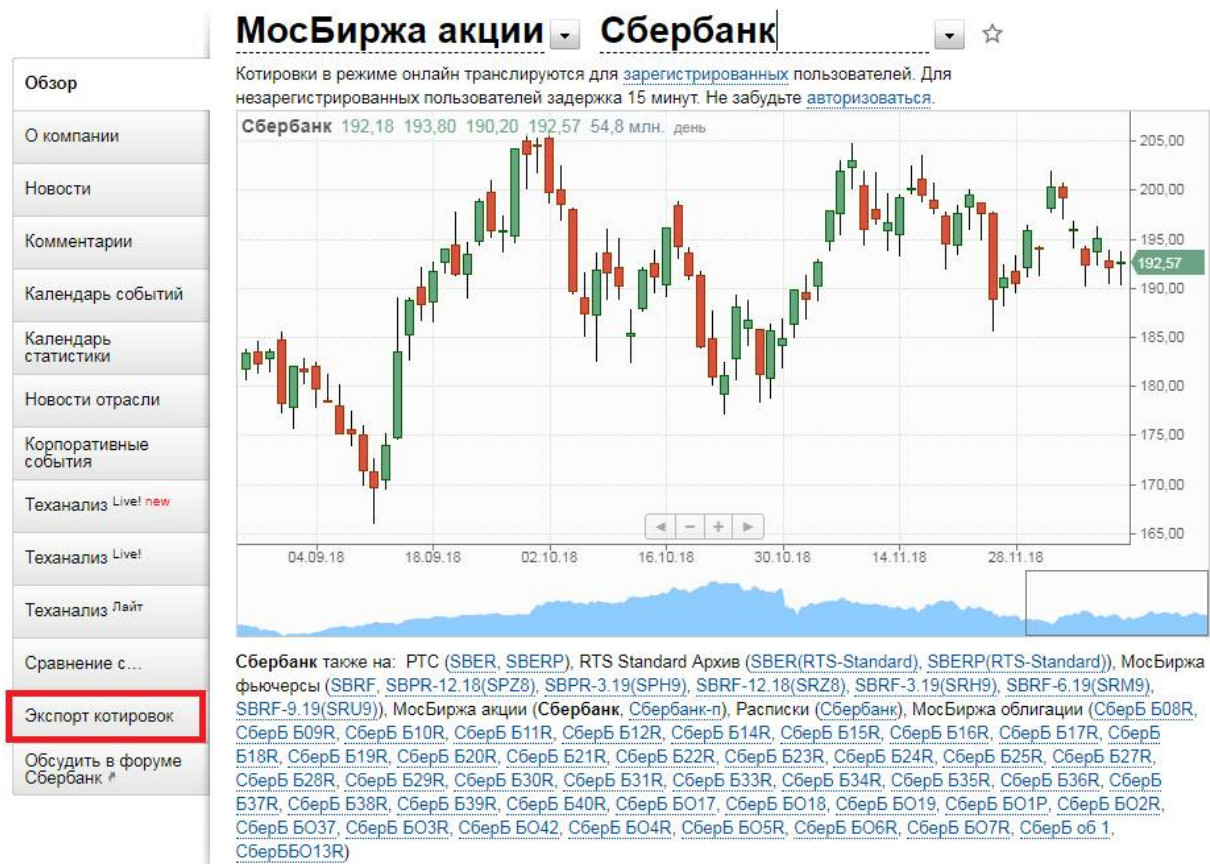


Рисунок 1.12. Котировки

МосБиржа акции **Сбербанк**

Интервал и периодичность: 01.01.2010 — 01.12.2018 1 день

Имя выходного файла: SBER_100101_181201 .txt

Имя контракта: SBER

Формат: даты: ggggmmdd времени: ччммсс

Выдавать время: ☐ начала свечи ☒ окончания свечи ☒ московское

Разделитель: полей: запятая (,) разрядов: нет

Формат записи в файл: TICKER, PER, DATE, TIME, OPEN, HIGH, LOW, CLOSE, VOL

Добавить заголовок файла: ☒

Заполнять периоды без сделок: ☐

Получить файл

На выходе вы получите текстовый файл, который через DownLoader Вы сможете легко конвертировать в формат

Рисунок 1.13. Экспорт котировки

1.6. Содержание отчета

1. Титульный лист.

2. Описание предметной области и постановка задачи.

3. Алгоритм по варианту.

4. Листинг программы.

5. Результаты работы программы:

- общий вид обучающей, проверочной и тестовой выборок;
- архитектура НС;
- таблица экспериментов подбора гиперпараметров;
- точность прогнозирования итоговой модели на обучающей и тестовой выборках;
- результаты прогнозирования итоговой модели на графиках (отдельно обучающая выборка, отдельно тестовая и обе на одном графике).

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Барсегян А. А. Анализ данных и процессов: учебное пособие [Электронный ресурс] / А. А. Барсегян, М. С. Куприянов, И. И. Холод, М. Д. Тесс, С. И. Елизаров. – 3-е изд., перераб. и доп. – 9Мб. — СПб.: БХВ-Петербург, 2009. – 1 файл. – Систем. требования: Acrobat Reader.

2. Дейтел Пол. Python: Искусственный интеллект, большие данные и облачные вычисления. [Электронный ресурс] / Дейтел Пол, Дейтел Харви — СПб.: Питер, 2020. — 864 с.: ил. — (Серия «Для профессионалов»). 1 файл. – Систем. требования: Acrobat Reader.

3. Антонио Джулли. Библиотека Keras – инструмент глубокого обучения. Реализация нейронных сетей с помощью библиотек Theano и TensorFlow [Электронный ресурс] Антонио Джулли, Суджит Пал / пер. с англ. Слинкин А.А. – М.: ДМК Пресс, 2018. -294 с.: ил. 1 файл. – Систем. требования: Acrobat Reader.

4. Жерон, Орельен. Прикладное машинное обучение с помощью Scikit-Learn и TensorFlow: концепции, инструменты и техники для создания интеллектуальных систем. [Электронный ресурс]. Пер. с англ. - СПб.: ООО «Альфа-книга»: 2018. - 688 с.: ил. 1 файл. – Систем. требования: Acrobat Reader.

5. Шакла Нивант. Машинное обучение и TensorFlow. - СПб.: Питер, 2019. - 336 с.: ил. - (Серия«Библиотека программиста»).

4. Федин Ф. О. Анализ данных. Часть 1. Подготовка данных к анализу: учебное пособие / Ф. О. Федин, Ф. Ф. Федин. — Москва: Московский городской педагогический университет, 2012. — 204 с. — ISBN 2227-8397. — Текст: электронный // Электронно-библиотечная система IPR BOOKS: [сайт]. — URL: <http://www.iprbookshop.ru/26444.html>. — Режим доступа: для авторизир. пользователей

5. Федин Ф. О. Анализ данных. Часть 2. Инструменты Data Mining: учебное пособие / Ф. О. Федин, Ф. Ф. Федин. — Москва: Московский городской педагогический университет, 2012. — 308 с. — ISBN 2227-8397. — Текст: электронный // Электронно-библиотечная система IPR BOOKS: [сайт]. — URL: <http://www.iprbookshop.ru/26445.html>. — Режим доступа: для авторизир. пользователей

МЕТОДИЧЕСКИЕ РЕКОМЕНДАЦИИ
для выполнения контрольных работ по дисциплине
«Интеллектуальный анализ данных»

Составитель:

Васяева Татьяна Александровна – кандидат технических наук, доцент кафедры автоматизированных систем управления ГОУВПО «ДОННТУ»

Ответственный за выпуск:

Секирин Александр Иванович – кандидат технических наук, доцент, заведующий кафедрой автоматизированных систем управления ГОУВПО «ДОННТУ»